LAPORAN PRAKTIKUM

APPILIED MECHINE LEARNING

OLEH :

ELA LESTARI

105841109223

FAKULTAS TEKNIK JURUSAN INFORMATIKA

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

PERTEMUAN II

“DATA PREPROCESSING DAN EDA”

1. Import Library & Load Data

Kode tersebut berfungsi untuk menyiapkan dan memahami dataset Titanic dari library Seaborn sebelum dilakukan analisis lebih lanjut. Library pandas digunakan untuk mengelola data dalam bentuk tabel (DataFrame), seaborn untuk memuat dataset dan membantu visualisasi, matplotlib.pyplot untuk menampilkan grafik, StandardScaler dari sklearn untuk proses standarisasi data numerik, dan numpy untuk operasi numerik. Perintah sns.load_dataset("titanic") digunakan untuk memuat dataset ke dalam variabel df, kemudian df.shape menampilkan ukuran dataset berupa jumlah baris dan kolom, sedangkan df.dtypes menampilkan tipe data setiap kolom (seperti numerik, kategorikal, atau boolean).

Langkah ini penting sebagai tahap awal eksplorasi data (data understanding) agar kita mengetahui struktur data dan dapat menentukan metode preprocessing yang tepat.

- Code

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler
import numpy as np

# Load dataset Titanic
df = sns.load_dataset("titanic")

# Ukuran data
print("Ukuran Data:", df.shape)

# Tipe kolom
print("\nTipe Kolom:")
print(df.dtypes)
```

✓ 0.0s

- Output

```
Ukuran Data: (891, 15)

Tipe Kolom:
survived           int64
pclass             int64
sex               object
age              float64
sibsp              int64
parch              int64
fare             float64
embarked          object
class           category
who               object
adult_male          bool
deck            category
embark_town       object
alive             object
alone               bool
dtype: object
```

2. Tangani Missing Value

Kode tersebut digunakan untuk menangani missing value pada dataset Titanic dari Seaborn. Pertama, df.isnull().sum() menampilkan jumlah nilai kosong pada setiap kolom sebelum dilakukan pembersihan data. Selanjutnya, kolom age yang bertipe numerik diisi menggunakan nilai median karena median lebih tahan terhadap outlier dibandingkan mean. Kolom embarked yang bertipe kategorikal diisi menggunakan modus (nilai yang paling sering muncul) karena metode ini paling sesuai untuk data kategori. Kolom deck dihapus menggunakan drop(columns=["deck"]) karena memiliki persentase missing value yang sangat besar (lebih dari 70%) sehingga kurang informatif jika dipertahankan. Terakhir, df.isnull().sum() kembali ditampilkan untuk memastikan bahwa missing value sudah berhasil ditangani.

- Code

```python
print("\nMissing Value Sebelum:")
print(df.isnull().sum())

# age → median (karena numerik & tahan outlier)
df["age"] = df["age"].fillna(df["age"].median())

# embarked → modus (karena kategorikal)
df["age"] = df["age"].fillna(df["age"].median())
df["embarked"] = df["embarked"].fillna(df["embarked"].mode()[0])

# deck → dihapus karena terlalu banyak missing (>70%)
df = df.drop(columns=["deck"])

print("\nMissing Value Sesudah:")
print(df.isnull().sum())
```

✓ 0.1s

- Output

```
Missing Value Sebelum:
survived         0
pclass           0
sex              0
age            177
sibsp            0
parch            0
fare             0
embarked         2
class            0
who              0
adult_male       0
deck           688
embark_town      2
alive            0
alone            0
dtype: int64

Missing Value Sesudah:
survived       0
pclass         0
sex            0
age            0
sibsp          0
...
embark_town    2
alive          0
alone          0
dtype: int64
```

3. **Tangani outlier**

Kode tersebut digunakan untuk menangani outlier pada dua kolom numerik, yaitu fare dan age, menggunakan metode IQR (Interquartile Range) pada dataset Titanic dari Seaborn. Pertama, dihitung nilai kuartil pertama (Q1) dan kuartil ketiga (Q3), kemudian IQR diperoleh dari selisih Q3 − Q1. Batas bawah (low) dan batas atas (high) ditentukan dengan rumus Q1 − 1.5×IQR dan Q3 + 1.5×IQR. Nilai yang berada di luar batas tersebut tidak dihapus, tetapi dipotong (clipping) menggunakan fungsi clip() agar tetap berada dalam rentang yang wajar tanpa mengurangi jumlah data. Proses ini dilakukan pada kolom fare dan age untuk mengurangi pengaruh nilai ekstrem terhadap analisis. Terakhir, perintah describe() digunakan untuk menampilkan statistik deskriptif (count, mean, std, min, 25%, 50%, 75%, max) setelah outlier ditangani, sehingga dapat dilihat bahwa nilai minimum dan maksimum sudah lebih terkendali.

- Code

```python
# OUTLIER HANDLING (IQR)

# Fare
q1, q3 = df["fare"].quantile([0.25, 0.75])
iqr = q3 - q1
low, high = q1 - 1.5*iqr, q3 + 1.5*iqr
df["fare"] = df["fare"].clip(low, high)

# Age
q1_age, q3_age = df["age"].quantile([0.25, 0.75])
iqr_age = q3_age - q1_age
low_age, high_age = q1_age - 1.5*iqr_age, q3_age + 1.5*iqr_age
df["age"] = df["age"].clip(low_age, high_age)

print("=== DESKRIPSI DATA SETELAH OUTLIER HANDLING ===")
print(df[["age", "fare"]].describe())
✓ 0.1s
```

- Output

```
=== DESKRIPSI DATA SETELAH OUTLIER HANDLING ===
              age        fare
count  891.000000  891.000000
mean    29.039282   24.046813
std     12.072074   20.481625
min      2.500000    0.000000
25%     22.000000    7.910400
50%     28.000000   14.454200
75%     35.000000   31.000000
max     54.500000   65.634400
```

4. Lakukan scaling Kolom Numerik

Melakukan scaling (standardization) pada kolom numerik age dan fare pada dataset Titanic dari Seaborn menggunakan StandardScaler dari sklearn.preprocessing. Objek StandardScaler() dibuat lalu metode fit_transform() digunakan untuk menghitung rata-rata dan standar deviasi masing-masing kolom, kemudian mengubah datanya sehingga memiliki mean ≈ 0 dan standar deviasi ≈ 1. Proses ini penting agar fitur numerik berada dalam skala yang sama, terutama untuk algoritma machine learning yang sensitif terhadap perbedaan skala seperti KNN, SVM, dan Logistic Regression. Terakhir, perintah describe() digunakan untuk menampilkan statistik deskriptif setelah scaling sehingga dapat terlihat bahwa nilai rata-rata mendekati nol dan standar deviasi mendekati satu, menandakan proses standardisasi berhasil.

- Code

```
# SCALING (STANDARDIZATION)

from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
df[["age", "fare"]] = scaler.fit_transform(df[["age", "fare"]])

print("=== DESKRIPSI DATA SETELAH SCALING ===")
print(df[["age", "fare"]].describe())
✓ 0.7s
```

- Output

```
=== DESKRIPSI DATA SETELAH SCALING ===
                age          fare
count  8.910000e+02  8.910000e+02
mean   2.392400e-17  9.968332e-17
std    1.000562e+00  1.000562e+00
min   -2.199638e+00 -1.174727e+00
25%   -5.834321e-01 -7.882908e-01
50%   -8.613809e-02 -4.686152e-01
75%    4.940382e-01  3.396748e-01
max    2.110244e+00  2.031623e+00
```

5. Visualisasi & Insight

1. Survival Count

Kode ini diawali dengan plt.figure() untuk membuat area grafik baru. Selanjutnya, sns.countplot(x="survived", data=df) digunakan untuk membuat grafik batang yang menampilkan jumlah penumpang berdasarkan kolom survived, yaitu 0 (tidak selamat) dan 1 (selamat). Fungsi ini secara otomatis menghitung frekuensi setiap kategori dalam kolom tersebut. Kemudian plt.title() memberikan judul pada grafik agar mudah dipahami, dan plt.show() digunakan untuk menampilkan grafik ke layar.

2. Survival Berdasarkan Jenis Kelamin

Kode ini juga dimulai dengan plt.figure() untuk membuat kanvas grafik baru. Fungsi sns.countplot(x="sex", hue="survived", data=df) membuat grafik batang berdasarkan jenis kelamin pada sumbu X, lalu membaginya lagi

berdasarkan status keselamatan menggunakan parameter hue. Artinya, dalam setiap kategori laki-laki dan perempuan akan ditampilkan pembagian jumlah yang selamat dan tidak selamat. plt.title() menambahkan judul grafik, dan plt.show() menampilkan hasil visualisasi.

3. Distribusi Umur

Pada bagian ini, plt.figure() membuat area grafik baru, kemudian sns.histplot(df["age"], bins=20, kde=True) digunakan untuk membuat histogram distribusi umur. Parameter bins=20 membagi data umur menjadi 20 interval kelompok, sedangkan kde=True menambahkan garis kurva distribusi (Kernel Density Estimation) untuk memperjelas pola sebaran data. Judul grafik ditambahkan dengan plt.title(), dan plt.show() menampilkan hasilnya.

4. Fare Berdasarkan Kelas

Kode ini membuat visualisasi boxplot menggunakan sns.boxplot(x="pclass", y="fare", data=df). Sumbu X menampilkan kelas tiket (pclass), sedangkan sumbu Y menunjukkan harga tiket (fare). Boxplot digunakan untuk melihat median, kuartil, penyebaran data, serta potensi outlier pada setiap kelas tiket. plt.figure() membuat kanvas grafik, plt.title() memberi judul, dan plt.show() menampilkan visualisasi.

5. Heatmap Korelasi

Kode ini diawali dengan plt.figure() lalu menghitung korelasi antar variabel numerik menggunakan df.corr(numeric_only=True). Hasil korelasi tersebut divisualisasikan dengan sns.heatmap(), di mana annot=True menampilkan angka nilai korelasi di dalam setiap kotak, dan cmap="coolwarm" mengatur gradasi warna (biru untuk korelasi negatif dan merah untuk positif). plt.title() menambahkan judul grafik, dan plt.show() menampilkan heatmap sehingga hubungan antar variabel numerik dapat terlihat dengan jelas.

- Code

```python
#Visualisasi (Minimal 5)

import seaborn as sns
import matplotlib.pyplot as plt

1#Survival Count
#Jumlah penumpang yang tidak selamat lebih banyak dibanding yang selamat.
plt.figure()
sns.countplot(x="survived", data=df)
plt.title("Jumlah Penumpang Selamat vs Tidak")
plt.show()

2#Survival Berdasarkan Jenis Kelamin
#Perempuan memiliki tingkat keselamatan jauh lebih tinggi dibanding laki-laki (prioritas evakuasi).
plt.figure()
sns.countplot(x="sex", hue="survived", data=df)
plt.title("Survival Berdasarkan Jenis Kelamin")
plt.show()

3#Distribusi Umur
#Mayoritas penumpang berada pada usia 20–40 tahun.
plt.figure()
sns.histplot(df["age"], bins=20, kde=True)
plt.title("Distribusi Umur (Scaled)")
plt.show()

4#Fare Berdasarkan Kelas
#Penumpang kelas 1 membayar tiket lebih mahal dan memiliki peluang selamat lebih tinggi.
plt.figure()
sns.boxplot(x="pclass", y="fare", data=df)
plt.title("Fare Berdasarkan Kelas Tiket")
plt.show()

5#Heatmap Korelasi
#Terdapat korelasi:
        #Fare → positif terhadap survival
        #Pclass → negatif terhadap survival
        #Gender sangat berpengaruh terhadap keselamatan
plt.figure()
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap="coolwarm")
plt.title("Heatmap Korelasi")
plt.show()
✓ 2.8s
```

- Output

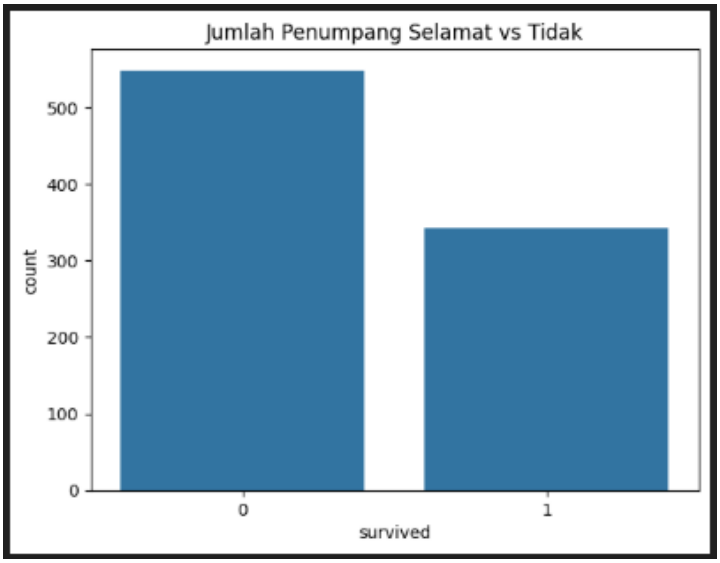

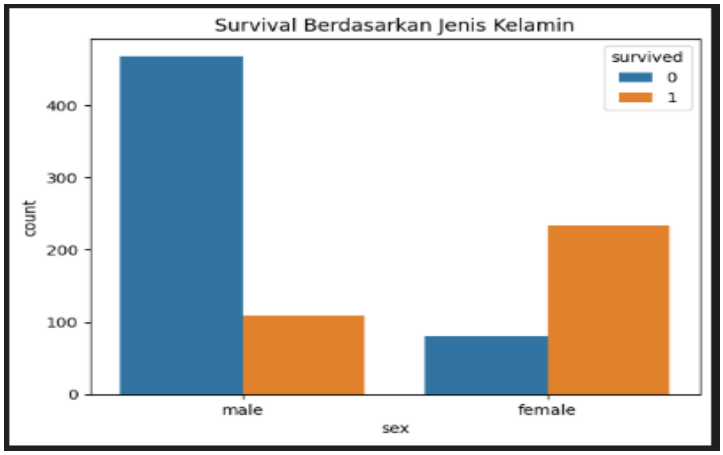
Survival Berdasarkan Jenis Kelamin
survived
0
1
count
400
300
200
100
0
male
female
sex

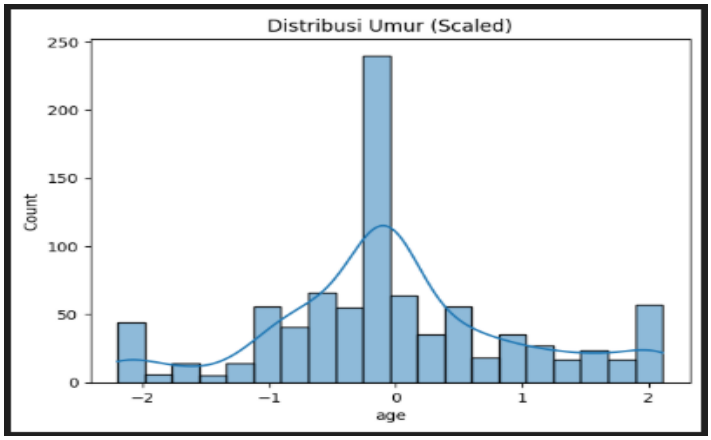
Distribusi Umur (Scaled)
Count
250
200
150
100
50
0
−2
−1
0
1
2
age

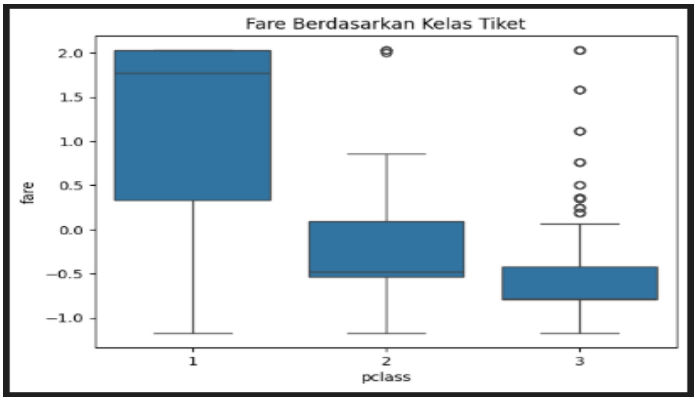
Fare Berdasarkan Kelas Tiket
fare
2.0
1.5
1.0
0.5
0.0
−0.5
−1.0
1
2
3
pclass

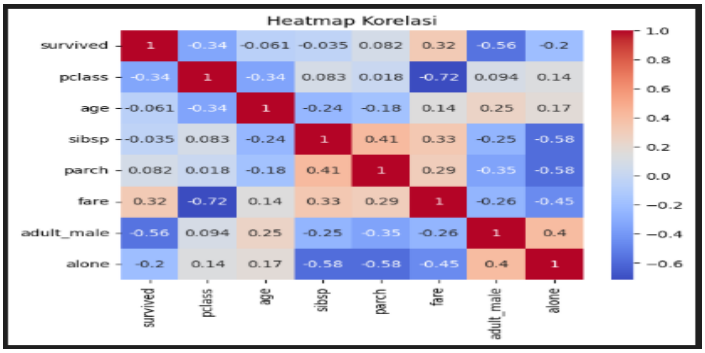
Heatmap Korelasi
survived 1 -0.34 -0.061 -0.035 0.082 0.32 -0.56 -0.2
pclass -0.34 1 -0.34 0.083 0.018 -0.72 0.094 0.14
age -0.061 -0.34 1 -0.24 -0.18 0.14 0.25 0.17
sibsp -0.035 0.083 -0.24 1 0.41 0.33 -0.25 -0.58
parch 0.082 0.018 -0.18 0.41 1 0.29 -0.35 -0.58
fare 0.32 -0.72 0.14 0.33 0.29 1 -0.26 -0.45
adult_male -0.56 0.094 0.25 -0.25 -0.35 -0.26 1 0.4
alone -0.2 0.14 0.17 -0.58 -0.58 -0.45 0.4 1
survived
pclass
age
sibsp
parch
fare
adult_male
alone
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6

6. Kesimpulan

Berdasarkan hasil preprocessing dan eksplorasi data (EDA) pada dataset Titanic dari Seaborn, dapat disimpulkan bahwa proses pembersihan data sangat penting sebelum analisis dilakukan. Missing value berhasil ditangani dengan metode yang sesuai dengan tipe data, yaitu median untuk data numerik (age) dan modus untuk data kategorikal (embarked), serta penghapusan kolom deck karena memiliki terlalu banyak nilai kosong. Outlier pada kolom age dan fare ditangani menggunakan metode IQR sehingga nilai ekstrem tidak lagi mendistorsi analisis, dan scaling menggunakan StandardScaler membuat data numerik berada dalam skala yang seragam.

Dari hasil visualisasi, diketahui bahwa jumlah penumpang yang tidak selamat lebih banyak dibandingkan yang selamat. Faktor jenis kelamin dan kelas tiket memiliki pengaruh yang signifikan terhadap tingkat keselamatan, di mana perempuan dan penumpang kelas 1 memiliki peluang selamat lebih tinggi. Selain itu, harga tiket (fare) menunjukkan korelasi positif terhadap keselamatan, sedangkan kelas tiket (pclass) menunjukkan korelasi negatif terhadap keselamatan. Secara keseluruhan, analisis ini menunjukkan bahwa faktor sosial dan ekonomi berperan penting dalam tingkat keselamatan penumpang Titanic.