LAPORAN PRAKTIKUM

APPILIED MECHINE LEARNING

OLEH :

ELA LESTARI

105841109223

FAKULTAS TEKNIK JURUSAN INFORMATIKA

UNIVERSITAS MUHAMMADIYAH MAKASSAR

2026

PERTEMUAN VI

“ENSEMBLE METHODS (RANDOM FOREST & GRADIENT BOOSTING)”

1. **Bandingkan Decision Tree vs Random Forest vs Gradient Boosting (classification).**

   Mengimpor berbagai modul yang diperlukan dalam proses machine learning. load_breast_cancer digunakan untuk memuat dataset Breast Cancer yang sudah tersedia dalam library Scikit-learn. train_test_split digunakan untuk membagi dataset menjadi data latih (training) dan data uji (testing). StandardScaler digunakan untuk melakukan normalisasi atau standarisasi nilai fitur agar berada pada skala yang sama.

   a) Perbandingan

   Kode tersebut berfungsi untuk membandingkan performa tiga algoritma klasifikasi, yaitu Decision Tree (DT), Random Forest (RF), dan Gradient Boosting (GB), pada dataset Breast Cancer. Pertama, dibuat dictionary models yang berisi ketiga model dengan parameter default, di mana Random Forest menggunakan n_estimators=100 untuk menentukan jumlah pohon, dan semua model menggunakan random_state=42 agar hasilnya konsisten. Selanjutnya, melalui perulangan for, setiap model dilatih menggunakan data training (model.fit(X_train, y_train)), kemudian digunakan untuk memprediksi data testing (model.predict(X_test)). Hasil prediksi dibandingkan dengan label asli menggunakan accuracy_score untuk menghitung akurasi model, yang kemudian dibulatkan tiga angka desimal dan disimpan dalam dictionary results. Terakhir, nilai akurasi masing-masing model ditampilkan ke layar agar dapat dibandingkan performanya secara langsung.

- Code

```python
import numpy as np
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
from sklearn.metrics import accuracy_score

# ============================================================
# Load Dataset
# ============================================================
data = load_breast_cancer()

X_train, X_test, y_train, y_test = train_test_split(
    data.data, data.target, test_size=0.2, random_state=42
)

# ============================================================
# Tugas 1: Bandingkan DT vs RF vs GB (Classification)
# ============================================================
print("=" * 55)
print("Tugas 1: Perbandingan DT vs RF vs GB (Classification)")
print("=" * 55)

models = {
    "DecisionTree": DecisionTreeClassifier(random_state=42),
    "RandomForest": RandomForestClassifier(n_estimators=100, random_state=42),
    "GradientBoosting": GradientBoostingClassifier(random_state=42),
}

results = {}

for name, model in models.items():

    model.fit(X_train, y_train)

    pred = model.predict(X_test)

    acc = round(accuracy_score(y_test, pred), 3)

    results[name] = acc

    print(f"{name:20s} accuracy: {acc}")
```

- Output

```
=======================================================
Tugas 1: Perbandingan DT vs RF vs GB (Classification)
=======================================================
DecisionTree         accuracy: 0.947
RandomForest         accuracy: 0.965
GradientBoosting     accuracy: 0.956
```

2. **Tampilkan 10 fitur terpenting dari Random Forest.**

Kode tersebut berfungsi untuk menentukan dan menampilkan 10 fitur paling penting (feature importance) dari model Random Forest pada dataset Breast Cancer. Pertama, model Random Forest yang sudah dilatih diambil dari dictionary models. Kemudian, atribut rf.feature_importances_ digunakan untuk menghitung tingkat kontribusi masing-masing fitur terhadap keputusan klasifikasi. Fungsi np.argsort(importances)[::-1][:10] digunakan untuk mengurutkan fitur berdasarkan nilai pentingnya dari yang terbesar dan mengambil 10 fitur teratas. Selanjutnya, melalui perulangan for, setiap fitur

teratas ditampilkan bersama peringkat dan nilai pentingnya (importance) dengan format rapi, sehingga dapat diketahui fitur mana yang paling berpengaruh terhadap prediksi kanker payudara oleh model Random Forest.

- Code

```python
# ========================================================
# Tugas 2: Top 10 Feature Importance dari Random Forest
# ========================================================
print("\n" + "=" * 55)
print("Tugas 2: Top 10 Feature Importance (Random Forest)")
print("=" * 55)

rf = models["RandomForest"]

importances = rf.feature_importances_

indices = np.argsort(importances)[::-1][:10]

for rank, idx in enumerate(indices, 1):

    print(f"{rank:2d}. {data.feature_names[idx]:30s} importance: {importances[idx]:.4f}")
```

✓ 0.0s

- Output

```
=======================================================
Tugas 2: Top 10 Feature Importance (Random Forest)
=======================================================
 1. worst area                    importance: 0.1539
 2. worst concave points          importance: 0.1447
 3. mean concave points           importance: 0.1062
 4. worst radius                  importance: 0.0780
 5. mean concavity                importance: 0.0680
 6. worst perimeter               importance: 0.0671
 7. mean perimeter                importance: 0.0533
 8. mean radius                   importance: 0.0487
 9. mean area                     importance: 0.0476
10. worst concavity               importance: 0.0318
```

3. Ubah n_estimators

Kode tersebut berfungsi untuk menguji pengaruh parameter n_estimators pada performa model Random Forest. Program melakukan perulangan untuk beberapa nilai n_estimators (10, 50, 100, 200, 500), di mana untuk setiap nilai dibuat model Random Forest baru, dilatih dengan data training, dan diuji pada data testing menggunakan accuracy_score. Hasil akurasi ditampilkan ke layar, dan nilai terbaik disimpan untuk menentukan jumlah pohon yang menghasilkan akurasi tertinggi. Bagian terakhir menampilkan model terbaik beserta nilai n_estimators dan akurasinya, serta memberikan penjelasan singkat bahwa semakin banyak pohon, prediksi menjadi lebih stabil karena

voting dari banyak tree, tetapi peningkatan akurasi tidak selalu signifikan jika pohon terlalu banyak dan waktu komputasi akan lebih lama.

- Code

```python
# ============================================================
# Tugas 3: Ubah n_estimators dan lihat pengaruhnya
# ============================================================
print("\n" + "=" * 55)
print("Tugas 3: Pengaruh n_estimators pada Random Forest")
print("=" * 55)

best_acc = 0
best_n = 0

for n in [10, 50, 100, 200, 500]:

    rf_n = RandomForestClassifier(n_estimators=n, random_state=42)

    rf_n.fit(X_train, y_train)

    acc = accuracy_score(y_test, rf_n.predict(X_test))

    print(f"n_estimators={n:>3d} -> accuracy: {acc:.3f}")

    # menyimpan model terbaik
    if acc > best_acc:
        best_acc = acc
        best_n = n

# ============================================================
# Model Terbaik
# ============================================================
print("\n" + "=" * 55)
print("Model Terbaik Random Forest")
print("=" * 55)

print(f"n_estimators terbaik = {best_n}")
print(f"Akurasi terbaik     = {best_acc:.3f}")
```

```python
# ============================================================
# Penjelasan Pengaruh n_estimators
# ============================================================
print("\nAlasan:")
print("1. n_estimators adalah jumlah pohon keputusan dalam Random Forest.")
print("2. Semakin banyak pohon, model biasanya menjadi lebih stabil karena prediksi menggunakan voting dari banyak tree.")
print("3. Namun jika jumlah pohon terlalu banyak, peningkatan akurasi tidak selalu signifikan dan waktu komputasi menjadi lebih lama.")
```

- Output

```
=======================================================
Tugas 3: Pengaruh n_estimators pada Random Forest
=======================================================
n_estimators= 10 -> accuracy: 0.956
n_estimators= 50 -> accuracy: 0.965
n_estimators=100 -> accuracy: 0.965
n_estimators=200 -> accuracy: 0.965
n_estimators=500 -> accuracy: 0.965

=======================================================
Model Terbaik Random Forest
=======================================================
n_estimators terbaik = 50
Akurasi terbaik     = 0.965

Alasan:
1. n_estimators adalah jumlah pohon keputusan dalam Random Forest.
2. Semakin banyak pohon, model biasanya menjadi lebih stabil karena prediksi menggunakan voting dari banyak tree.
3. Namun jika jumlah pohon terlalu banyak, peningkatan akurasi tidak selalu signifikan dan waktu komputasi menjadi lebih lama.
```

4. **Kesimpulan: 3 poin kesimpulan**

Percobaan ini menunjukkan bahwa model ensemble seperti Random Forest dan Gradient Boosting umumnya lebih akurat dibanding Decision Tree tunggal karena prediksi dilakukan berdasarkan voting dari banyak pohon sehingga lebih stabil dan mengurangi risiko overfitting; analisis feature importance pada Random Forest juga memperlihatkan bahwa beberapa fitur memiliki pengaruh jauh lebih besar terhadap prediksi kanker payudara, sehingga fokus pada fitur ini dapat meningkatkan efisiensi model; selain itu, meningkatkan jumlah pohon (n_estimators) dalam Random Forest dapat meningkatkan akurasi dan stabilitas model hingga titik tertentu, tetapi peningkatan akurasi tidak selalu signifikan jika jumlah pohon terlalu banyak, sementara waktu komputasi akan lebih lama, sehingga pemilihan n_estimators perlu mempertimbangkan keseimbangan antara performa dan efisiensi.